Регламент обработки документов

1. Общие положения

Настоящий регламент определяет порядок приёма, хранения и обработки документов в информационной системе компании. Регламент обязателен для всех сотрудников, работающих с корпоративной базой знаний.

Документом считается любой файл в формате PDF или Markdown, содержащий текстовый слой. Сканированные копии без распознанного текста в систему не принимаются, поскольку поиск по ним невозможен.

2. Загрузка документов

Загрузку выполняет администратор через программный интерфейс. Каждый запрос сопровождается ключом доступа, который выдаётся службой информационной безопасности и хранится только в переменных окружения.

Размер одного файла не должен превышать двадцати мегабайт. Если файл с тем же содержимым уже загружен, система возвращает идентификатор существующего документа и не создаёт дубликатов.

При загрузке новой версии документа с тем же именем старые фрагменты удаляются, а вместо них сохраняются фрагменты

новой версии. История версий в системе не ведётся.

3. Хранение и поиск

Текст документа делится на фрагменты, каждый из которых сохраняется вместе с номером страницы и названием раздела. Эти сведения используются для ссылки на источник в ответе ассистента.

Для каждого фрагмента вычисляется векторное представление, по которому выполняется семантический поиск. Дополнительно строится полнотекстовый индекс на русском языке, учитывающий морфологию слов.

Фрагменты, найденные обоими способами, объединяются, после чего наиболее подходящие из них передаются языковой модели вместе с вопросом пользователя.

4. Ответственность

Ответственность за актуальность документов несёт владелец соответствующего процесса. Устаревшие документы удаляются из системы не позднее одного рабочего дня после выхода новой редакции.

Контроль исполнения настоящего регламента возлагается на руководителя отдела информационных технологий.